

Trabajo de Aprendizaje por Refuerzo: Caminante Bípido

Jorge Bengoa Pinedo

Bogurad Barański Barańska

Máster TECI - Redes neuronales y aprendizaje estadístico

1 de marzo de 2026

1. Introducción

En este trabajo se busca abordar mediante aprendizaje por refuerzo el problema del caminante bípido (*Bipedal Walker*) que consiste en enseñar a un robot en el entorno virtual *Gymnasium* a andar. Para ello, se dispone de los datos de 24 sensores, tal y como se puede ver en la figura 1, que conforman el espacio de observaciones. A partir de esta información, el robot debe tomar decisiones dinámicas mediante sus 4 actuadores, situados cada uno en una articulación. Estos actuadores se encargan de estabilizar y ejercer movimiento sobre el robot aplicando una velocidad de rotación comprendida entre -1 y 1 rad/s .




Figura 1: Mapping of the 24-Dimensional Observation Space for the BipedalWalker-v3 Environment

Por tanto, en este trabajo, para la resolución del problema planteado anteriormente se propone abordarlo mediante aprendizaje por refuerzo y, en concreto, utilizando el paradigma de *Soft Actor Critic* descrito en los fundamentos matemáticos a continuación. Este se implementa en *Python* mediante librerías estándar de *stable_baselines3*, donde primero se realiza una búsqueda exhaustiva de hiperparámetros mediante optimización con *optuna*, para luego entrenar un

modelo con los mejores parámetros y ver si el agente aprende a andar.

Por último, es importante destacar que el objetivo fundamental del aprendizaje por refuerzo en este entorno es que el robot logre cruzar el terreno por completo. Para ello, la función de recompensa se define bajo dos premisas clave: el agente acumula progresivamente hasta 300 puntos si consigue llegar a la meta, pero sufre una fuerte penalización de -100 puntos en el instante en que su cuerpo principal entra en contacto con el suelo. Además, se aplica un castigo por el uso excesivo de torque en los articulaciones. Esta limitación tiene como propósito desincentivar los movimientos erráticos y asegurar que la marcha aprendida sea transferible a casos reales, donde la saturación de los motores tiene un alto coste físico.

2. Fundamentos matemáticos

Los apartados de procesos de decisión de Markov, aprendizaje por diferencias temporales y métodos de gradiente de política se basan en los capítulos 3, 6 y 13 de [1], respectivamente. El subapartado sobre soft actor-critic se apoya en [2].

2.1. Procesos de decisión de Markov

Los procesos de decisión de Markov (MDP) sirven para modelar el aprendizaje mediante interacción para conseguir un objetivo. Los MDP comprenden dos elementos:

- Agente: es el que aprende y toma decisiones.
- Entorno: comprende todo lo que es externo al agente e interactúa con el agente.

Cuando el agente toma una decisión, el entorno presenta una nueva situación al agente. Además, le entrega una recompensa. Mediante sus acciones, el agente busca maximizar la recompensa obtenida a lo largo del tiempo. La figura 2 refleja estas interacciones.




Figura 2: Interacción entre agente y entorno a través de un proceso de decisión de Markov.

Sean $\mathcal{S}$, $\mathcal{A}$ y $\mathcal{R}$ los conjuntos de estados, acciones y recompensas, respectivamente, entonces:

$$\begin{aligned}
 p &: \mathcal{S} \times \mathcal{R} \times \mathcal{S} \times \mathcal{A} \rightarrow [0, 1] \\
 p(s', r \mid s, a) &= \Pr\{S_t = s', R_t = r \mid S_{t-1} = s, A_{t-1} = a\} \\
 \sum_{s' \in \mathcal{S}} \sum_{r \in \mathcal{R}} p(s', r \mid s, a) &= 1, \quad \forall s \in \mathcal{S}, a \in \mathcal{A}(s)
 \end{aligned} \tag{1}$$

Donde $s, s' \in \mathcal{S}$, $r \in \mathcal{R}$, $a \in \mathcal{A}$. A partir de la ecuación anterior, se puede calcular la probabilidad marginal del siguiente estado:

$$\begin{aligned}
p : \mathcal{S} \times \mathcal{S} \times \mathcal{A} &\rightarrow [0, 1] \\
p(s' \mid s, a) &= \Pr\{S_t = s' \mid S_{t-1} = s, A_{t-1} = a\} = \sum_{r \in \mathcal{R}} p(s', r \mid s, a)
\end{aligned} \tag{2}$$

Y la recompensa esperada:

$$\begin{aligned}
r : \mathcal{S} \times \mathcal{A} &\rightarrow \mathbb{R} \\
r(s, a) &= \mathbb{E}[R_t \mid S_{t-1} = s, A_{t-1} = a] = \sum_{r \in \mathcal{R}} r \cdot p(r \mid s, a) = \sum_{r \in \mathcal{R}} r \sum_{s' \in \mathcal{S}} p(s', r \mid s, a)
\end{aligned} \tag{3}$$

2.1.1. Aprendizajes episódico y continuo

El objetivo del agente es maximizar la recompensa esperada en el largo plazo. Esto implica conocer cómo una acción presente repercute en los sucesivos pasos temporales. Según se tenga un estado final o no, se distingue entre:

- Aprendizaje episódico: cada episodio tiene una duración T finita, que no tiene por qué ser fija (p.ej. partidas de ajedrez). La recompensa esperada a maximizar se podría escribir como:

$$G_t = R_{t+1} + R_{t+2} + \dots + R_T \tag{4}$$

- Aprendizaje continuo: las interacciones agente-entorno no tienen un fin o este es muy lejano (p.ej. un robot *pick and place*). En tal caso, la definición anterior podría tomar el valor ∞ . Para evitarlo, se define la recompensa descontada:

$$G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1} = R_{t+1} + \gamma \sum_{k=1}^{\infty} \gamma^{k-1} R_{t+k+1} = R_{t+1} + \gamma G_{t+1} \tag{5}$$

Donde γ es el factor de descuento. Si $\gamma < 1$, el sumatorio converge a un valor finito. Cuanto mayor sea el valor de γ , mayor visión a futuro tendrá el agente.

Se puede adoptar una notación común a ambos problemas:

$$G_t = \sum_{k=t+1}^T \gamma^{k-t-1} R_k \tag{6}$$

Donde las condiciones $\gamma = 1$ y $T = \infty$ son mutuamente excluyentes y representan los casos episódico y continuo de forma excluyente.

2.1.2. Políticas y funciones de valor

Una política define la probabilidad de que el agente tome una determinada acción dado un estado. Se denotará por $\pi(a \mid s)$.

Por otro lado, las funciones de valor pueden ser:

- Funciones de estado-valor: determinan cómo de bueno es que el agente esté en un determinado estado:

$$v_\pi(s) = \mathbb{E}_\pi[G_t \mid S_t = s] = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \mid S_t = s \right], \forall s \in \mathcal{S} \tag{7}$$

La función estado-valor óptima es:

$$v_*(s) = \max_{\pi} v_{\pi}(s), \forall s \in \mathcal{S} \quad (8)$$

- Funciones de acción-valor: determinan cómo de bueno es que el agente tome una determinada acción dado un estado:

$$q_{\pi}(s, a) = \mathbb{E}_{\pi}[G_t \mid S_t = s, A_t = a] = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k R_{t+k+1} \mid S_t = s, A_t = a \right] \quad (9)$$

Se dice que una política es óptima si $v_*(s) \geq v_{\pi}(s), \forall s \in \mathcal{S}, \forall \pi$. La función acción-valor óptima es:

$$q_*(s, a) = \max_{\pi} q_{\pi}(s, a) = \mathbb{E}[R_{t+1} + \gamma v_*(S_{t+1}) \mid S_t = s, A_t = a], \forall s \in \mathcal{S}, a \in \mathcal{A} \quad (10)$$

A partir de las expresiones anteriores se deduce la ecuación de expectativa de Bellman sobre la función estado-valor:

$$\begin{aligned} v_{\pi}(s) &= \mathbb{E}_{\pi}[G_t \mid S_t = s] = \mathbb{E}_{\pi}[R_{t+1} + \gamma G_{t+1} \mid S_t = s] \\ &= \sum_{a \in \mathcal{A}} \pi(a \mid s) \mathbb{E}_{\pi}[R_{t+1} + \gamma G_{t+1} \mid S_t = s, A_t = a] && \text{(Ley de la probabilidad total)} \\ &= \sum_{a \in \mathcal{A}} \pi(a \mid s) \sum_{s' \in \mathcal{S}} \sum_{r \in \mathcal{R}} p(s', r \mid s, a) \cdot \\ &\quad \mathbb{E}_{\pi}[R_{t+1} + \gamma G_{t+1} \mid S_t = s, A_t = a, S_{t+1} = s', R_{t+1} = r] && \text{(Ley de la probabilidad total)} \\ &= \sum_{a \in \mathcal{A}} \pi(a \mid s) \sum_{s', r} p(s', r \mid s, a) \mathbb{E}_{\pi}[R_{t+1} + \gamma G_{t+1} \mid S_{t+1} = s'] && \text{(Propiedad Markoviana)} \\ &= \sum_{a \in \mathcal{A}} \pi(a \mid s) \sum_{s', r} p(s', r \mid s, a) \mathbb{E}_{\pi}[r + \gamma G_{t+1} \mid S_{t+1} = s'] && \text{(Propiedad Markoviana)} \\ &= \sum_{a \in \mathcal{A}} \pi(a \mid s) \sum_{s', r} p(s', r \mid s, a) [r + \gamma \mathbb{E}_{\pi}[G_{t+1} \mid S_{t+1} = s']] \\ &= \sum_{a \in \mathcal{A}} \pi(a \mid s) \sum_{s', r} p(s', r \mid s, a) [r + \gamma v_{\pi}(s')] \end{aligned} \quad (11)$$

Análogamente, se puede obtener la ecuación de optimalidad de Bellman sobre la función estado-valor (nótese que la función estado-valor óptima corresponde con seguir la política óptima partiendo de la acción que maximiza la recompensa):

$$\begin{aligned} v_*(s) &= \max_{a \in \mathcal{A}(s)} q_{\pi^*}(s, a) \\ &= \max_a \mathbb{E}_{\pi^*}[G_t \mid S_t = s, A_t = a] \\ &= \max_a \mathbb{E}_{\pi^*}[R_{t+1} + \gamma G_{t+1} \mid S_t = s, A_t = a] \\ &= \max_a \mathbb{E}[R_{t+1} + \gamma v_*(S_{t+1}) \mid S_t = s, A_t = a] \\ &= \max_a \sum_{s', r} p(s', r \mid s, a) [r + \gamma v_*(s')] \end{aligned} \quad (12)$$

Las mismas ecuaciones de Bellman se pueden deducir para la función acción-valor:

$$q_\pi(s, a) = \mathbb{E}_\pi[R_{t+1} + \gamma G_{t+1} \mid S_t = s, A_t = a] = \sum_{s', r} p(s', r \mid s, a) [r + \gamma v_\pi(s')] \quad (13)$$

$$q_*(s, a) = \mathbb{E}_\pi[R_{t+1} + \gamma \max_{a'} q_*(S_{t+1}, a') \mid S_t = s, A_t = a] = \sum_{s', r} p(s', r \mid s, a) \left[r + \gamma \max_{a'} q_*(s', a') \right] \quad (14)$$

Conocido el valor de $v_*(s)$, bastaría con mirar el siguiente estado con ese valor esperado y seleccionar la acción que conduce a dicho estado. Como la información a largo plazo está codificada en la propia función estado-valor óptima, moverse de forma codiciosa (*greedy*), es decir, mirando solo al siguiente instante, ya implica tener en cuenta el futuro. Conocido $q_*(s, a)$, el problema es aún más fácil ya que no haría falta conocer que acción conduce al siguiente estado. Tan solo habría que seleccionar la acción cuyo valor sea óptimo.

Lógicamente, resolver las ecuaciones de Bellman puede no ser factible debido a que se necesitaría memoria y potencia computacional infinitas. Por lo tanto, se usan aproximaciones de las funciones estado-valor y acción-valor. Aunque los resultados son subóptimos, suelen funcionar razonablemente bien. Las políticas óptimas resultantes tienden a poner más esfuerzo en aprender de los estados que ocurren frecuente y menos esfuerzo en los menos habituales.

2.2. Aprendizaje por diferencias temporales

Idealmente, la política óptima se deriva de las ecuaciones de optimalidad de Bellman. Sin embargo, su resolución no es trivial, por lo que aparecen distintos esquemas para aproximar $v_*(s)$ y $q_*(s, a)$:

- Métodos de Monte-Carlo: no requieren un modelo del entorno. Las funciones de valor aproximadas se actualizan al final de cada episodio, estimando la esperanza a partir de una muestra.
- Programación dinámica: no requiere esperar al final de cada episodio para su actualización (permiten aprendizaje continuo), ya que calcula la esperanza exacta de las funciones de valor al suponer conocido un modelo del entorno.
- Diferencias temporales: aproximan las funciones valor sin necesidad de esperar el final de cada episodio ni de un modelo del entorno.

El enfoque de diferencias temporales combina las ventajas de los métodos de Monte-Carlo y la programación dinámica, haciéndolo flexible ante diversas situaciones.

2.2.1. Predicción TD

El problema de predicción consiste en estimar la función de valor v_π a partir de la experiencia siguiendo una política π . El método TD(0) es el más simple de todos. Actualiza su estimación en el instante $t + 1$ utilizando la recompensa inmediata observada y la estimación de v_π en el siguiente estado:

$$V(S_t) \leftarrow V(S_t) + \alpha [R_{t+1} + \gamma V(S_{t+1}) - V(S_t)] = V(S_t) + \alpha \delta_t \quad (15)$$

Donde $\alpha \in (0, 1]$ es la tasa de aprendizaje y $\delta_t = R_{t+1} + \gamma V(S_{t+1}) - V(S_t)$ es el error TD. Este último mide la diferencia entre la estimación actual, $V(S_t)$, y una estimación mejorada respaldada por la experiencia, $R_{t+1} + \gamma V(S_{t+1})$.

Otra ventaja de los métodos TD frente a Monte-Carlo es que son más robustos ante acciones arbitrarias de exploración. En los métodos de Monte-Carlo, este tipo de acciones podría distorsionar el valor de la esperanza, por lo que habría que descartar la iteración. Los métodos TD, por contra, aprenden de cada transición.

Los métodos TD convergen a la media de v_π si se sigue una política fija, π , y α es constante y suficientemente pequeño. La probabilidad de convergencia es 1 si α se reduce gradualmente, cumpliendo ciertas condiciones. No obstante, muchas de las pruebas de convergencia solo aplican al caso tabular.

Respecto a la velocidad de convergencia, los métodos TD convergen más rápido que Monte-Carlo de forma práctica, aunque no haya una demostración matemática. Esto ocurre para el formato online y batch (acumulando el error TD sobre todas las muestras disponibles antes de actualizar).

2.2.2. Control TD

El problema de control consiste en estimar $q_\pi(s, a)$. Por lo tanto, la actualización depende de los pares estado-acción. Existen distintas variantes de los métodos TD para este tipo de problemas:

- SARSA: es el caso más simple:

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha [R_{t+1} + \gamma Q(S_{t+1}, A_{t+1}) - Q(S_t, A_t)] \quad (16)$$

Es un algoritmo on-policy (la misma política seguida para la transición de estados es la que se actualiza) en el que continuamente se estima q_π a la vez que se va modificando la política π para que tienda a la codicia. Se empieza con una política que permite la exploración con una cierta probabilidad. Cada vez se favorece más las decisiones de explotación (seleccionar las recompensas que maximizan las acciones) en contra de dicha exploración.

- Q-learning: es un algoritmo off-policy que converge a q_* :

$$Q(S_t, A_t) \leftarrow Q(S_t, A_t) + \alpha [R_{t+1} + \gamma \max_a Q(S_{t+1}, a) - Q(S_t, A_t)] \quad (17)$$

La política de comportamiento para moverse por los estados puede elegirse libremente, lo que favorece la exploración. A medida que se van observando los estados, la política objetivo aprende a seleccionar la acción que maximiza la recompensa. Una ventaja de los métodos off-policy es que no importa cómo se han generado las muestras a la hora de actualizar la política objetivo, ya que ambas están desagregadas. Los métodos on-policy se actualizan de acuerdo a los estados explorados según la política actual. Es decir, no pueden reutilizar datos pasados porque fueron generados con una política diferente.

- Expected SARSA:

$$\begin{aligned} Q(S_t, A_t) &\leftarrow Q(S_t, A_t) + \alpha [R_{t+1} + \gamma \mathbb{E}_\pi [Q(S_{t+1}, A_{t+1}) \mid S_{t+1}] - Q(S_t, A_t)] \\ &= Q(S_t, A_t) + \alpha \left[R_{t+1} + \gamma \sum_a \pi(a \mid S_{t+1}) Q(S_{t+1}, a) - Q(S_t, A_t) \right] \end{aligned} \quad (18)$$

En vez de evaluar el siguiente par estado-acción, usa su valor esperado. La política objetivo π puede ser la misma que la de comportamiento (on-policy) o distinta (off-policy). Reduce

la varianza asociada a elegir una única acción A_{t+1} de forma aleatoria a cambio de un mayor coste computacional.

- Double-Q-learning: utiliza dos funciones de acción-valor para desacoplar la acción de la evaluación:

$$Q_1(S_t, A_t) \leftarrow Q_1(S_t, A_t) + \alpha \left[R_{t+1} + \gamma Q_2(S_{t+1}, \arg \max_a Q_1(S_{t+1}, a)) - Q_1(S_t, A_t) \right] \quad (19)$$

$$Q_2(S_t, A_t) \leftarrow Q_2(S_t, A_t) + \alpha \left[R_{t+1} + \gamma Q_1(S_{t+1}, \arg \max_a Q_2(S_{t+1}, a)) - Q_2(S_t, A_t) \right] \quad (20)$$

El Q-learning es optimista cuando las recompensas son ruidosas. Intuitivamente, se puede imaginar la situación en que los valores reales $q(s, a)$ son todos cero, pero sus estimaciones $Q(s, a)$ presentan incertidumbre. El máximo de los valores reales es cero, mientras que el máximo estimado es positivo. Esto se conoce como sesgo de maximización.

El double-Q-learning aborda este problema calculando simultáneamente dos funciones acción-valor: $Q_1(s, a)$ y $Q_2(s, a)$. Pero en cada iteración se actualiza solamente una de ellas a partir de la evaluación según la otra. Si una recompensa es ruidosa en torno a cero, será raro que tome valores positivos constantemente. Por ejemplo, para la primera muestra se actualiza Q_1 , que ve una recompensa muy alta. Si se usara Q-learning, otros pares estado-acción aumentarían su valor solamente por la expectativa de volver a repetir la jugada. Sin embargo, Q_2 evalúa el par estado-acción sin haber visto tal recompensa. Su percepción será que dicho par estado-acción no tiene tanto valor. Este proceso se repite actualizando arbitrariamente cada función.

2.3. Métodos de gradiente de política

Los métodos de control expuestos en la sección anterior se centran en aproximar la función acción-valor. Este tipo de enfoques se encuadra en lo que se conoce como métodos acción-valor: aprenden los valores de las acciones y selecciona una acción basándose en los valores aprendidos. La política se deriva implícitamente de la maximización $\arg \max_a Q(s, a)$.

Por otro lado, los métodos anteriores son tabulares: guardan registros con el valor de cada pareja acción-estado y los van actualizando. A medida que los espacios de estados y acciones crecen, los requisitos de memoria y tiempo para pasar por todos los estados se vuelven inasumibles. Los métodos aproximados buscan sustituir estas tablas por funciones matemáticas parametrizadas (p.ej. una red neuronal).

Los métodos de gradiente de política aprenden directamente los parámetros de una política, por lo que no necesitan consultar las funciones de valor para seleccionar una acción. Esto no significa que las funciones de valor no sean necesarias para aprender la política. El objetivo de los métodos de gradiente de política es obtener los parámetros que maximicen una medida de rendimiento $J(\theta)$:

$$\pi(a | s; \theta) = \Pr\{A_t = a | S_t = s; \theta_t = \theta\} \quad (21)$$

$$\theta_{t+1} = \theta_t + \alpha \widehat{\nabla_{\theta} J(\theta_t)} \quad (\text{Ascenso del gradiente}) \quad (22)$$

Los métodos que, además, aprenden una aproximación de las funciones de valor se denominan actor-crítico. El actor se relaciona con la política aprendida, mientras que el crítico se refiere

a la función de valor.

Los métodos de gradiente de política presentan algunas ventajas frente a los métodos acción-valor:

- Permiten aproximar políticas deterministas sin depender de parámetros de temperatura y exploración que son difíciles de ajustar.
- Permiten aproximar políticas estocásticas, superando a los métodos acción-valor que tienden a elegir $\arg \max_a Q(s, a)$.
- El cálculo de la política a veces puede ser más simple que el de la función acción-valor, que depende de la recompensa futura que se espera obtener.
- Se puede introducir conocimiento previo en la parametrización de la política.
- Las probabilidades de acción cambian de forma suave debido a que las políticas son continuas. En los métodos acción-valor se pueden dar saltos bruscos para cambios pequeños en los valores de las acciones debido a la función máximo.

Para el caso episódico ($\gamma = 1$), la medida de rendimiento es lo bien que está posicionado el algoritmo al inicio de cada episodio:

$$J(\theta) = v_{\pi_\theta}(s_0) \quad (23)$$

Donde v_{π_θ} es la función estado-valor real para la política π_θ . El gradiente del rendimiento se apoya en el teorema del gradiente de política:

$$\begin{aligned}
\nabla v_\pi(s) &= \nabla \left[\sum_a \pi(a|s) q_\pi(s, a) \right], \quad \forall s \in \mathcal{S} && \text{(Ley de la probabilidad total)} \\
&= \sum_a [\nabla \pi(a|s) q_\pi(s, a) + \pi(a|s) \nabla q_\pi(s, a)] && \text{(Derivada del producto)} \\
&= \sum_a \left[\nabla \pi(a|s) q_\pi(s, a) + \pi(a|s) \nabla \sum_{s', r} p(s', r|s, a) (r + v_\pi(s')) \right] && \text{(Ecuación de Bellman)} \\
&= \sum_a \left[\nabla \pi(a|s) q_\pi(s, a) + \pi(a|s) \sum_{s'} p(s'|s, a) \nabla v_\pi(s') \right] && \text{(Probabilidad marginal de } s') \\
&= \phi(s) + \underbrace{\sum_{s'} \sum_a \pi(a|s) p(s'|s, a) \nabla v_\pi(s')}_{\Pr(s \rightarrow s', 1, \pi)} && \left(\phi(s) = \sum_a \nabla \pi(a|s) q_\pi(s, a) \right) \\
&= \phi(s) + \sum_{s'} \Pr(s \rightarrow s', 1, \pi) \left[\phi(s') + \sum_{s''} \Pr(s' \rightarrow s'', 1, \pi) \nabla v_\pi(s'') \right] \\
&= \phi(s) + \sum_{s'} \Pr(s \rightarrow s', 1, \pi) \phi(s') \\
&\quad + \sum_{s''} \underbrace{\left(\sum_{s'} \Pr(s \rightarrow s', 1, \pi) \Pr(s' \rightarrow s'', 1, \pi) \right)}_{\Pr(s \rightarrow s'', 2, \pi)} \nabla v_\pi(s'') \\
&= \sum_{x \in \mathcal{S}} \sum_{k=0}^{\infty} \Pr(s \rightarrow x, k, \pi) \phi(x) && (24)
\end{aligned}$$

Aplicado al rendimiento para el caso episódico:

$$\begin{aligned}
\nabla J(\theta) &= \nabla v_\pi(s_0) \\
&= \sum_s \underbrace{\sum_{k=0}^{\infty} \Pr(s_0 \rightarrow s, k, \pi)}_{\eta(s)} \sum_a \nabla \pi(a|s) q_\pi(s, a) \\
&= \sum_{s'} \eta(s') \sum_s \underbrace{\frac{\eta(s)}{\sum_{s'} \eta(s')}}_{\mu(s)} \sum_a \nabla \pi(a|s) q_\pi(s, a) \quad (\text{Normalización}) \\
&\propto \sum_s \mu(s) \sum_a \nabla \pi(a|s) q_\pi(s, a) \quad \left(\sum_{s'} \eta(s') = \text{cte} \right) \quad (25)
\end{aligned}$$

2.3.1. REINFORCE

El sumatorio del teorema del gradiente de política puede ser inviable de calcular analíticamente. Una solución pasa por realizar una aproximación de Monte-Carlo mediante la esperanza sobre un conjunto de muestras. Dado que $\mu(s)$ representa la proporción de veces que se visita cada estado bajo la política π (i.e. la probabilidad de cada estado):

$$\nabla_\theta J(\theta) \propto \sum_s \mu(s) \sum_a q_\pi(s, a) \nabla_\theta \pi(a|s; \theta) = \mathbb{E}_\pi \left[\sum_a q_\pi(S_t, a) \nabla_\theta \pi(a | S_t; \theta) \right] \quad (26)$$

Es decir, obteniendo muestras de $\sum_a q_\pi(S_t, a) \nabla_\theta \pi(a | S_t; \theta)$ se podría aproximar la esperanza anterior. Dado que el espacio de acciones puede tener una elevada dimensión, se aproxima el sumatorio por otra esperanza (nótese que es necesario conocer la probabilidad con la que ocurre cada acción, $\pi(a | S_t; \theta)$):

$$\begin{aligned}
\nabla_\theta J(\theta) &\propto \mathbb{E}_\pi \left[\pi(a | S_t; \theta) \sum_a q_\pi(S_t, a) \frac{\nabla_\theta \pi(a | S_t; \theta)}{\pi(a | S_t; \theta)} \right] \\
&= \mathbb{E}_{S_t \sim \mu} [\mathbb{E}_{A_t \sim \pi} [q_\pi(S_t, A_t) \nabla_\theta \log \pi(A_t | S_t; \theta) | S_t]] \quad (\nabla \log(x) = \frac{\nabla x}{x}) \\
&= \mathbb{E}_{S_t \sim \mu, A_t \sim \pi} [q_\pi(S_t, A_t) \nabla_\theta \log \pi(A_t | S_t; \theta)] \quad (\text{Ley de la esperanza total}) \\
&= \mathbb{E}_{S_t, A_t} [\mathbb{E}_\pi [G_t | S_t, A_t] \nabla_\theta \log \pi(A_t | S_t; \theta)] \quad (q_\pi(S_t, A_t) = \mathbb{E}_\pi [G_t | S_t, A_t]) \\
&= \mathbb{E}_{S_t, A_t} [\mathbb{E}_\pi [G_t \nabla_\theta \log \pi(A_t | S_t; \theta) | S_t, A_t]] \\
&= \mathbb{E}_{S_t, A_t} [G_t \nabla_\theta \log \pi(A_t | S_t; \theta)] \quad (\text{Ley de la esperanza total}) \quad (27)
\end{aligned}$$

Aplicando el método de Monte-Carlo sobre la expresión final obtenida se aproxima la esperanza por la muestra de la iteración actual, dando lugar al esquema de actualización por ascenso del gradiente:

$$\theta_{t+1} = \theta_t + \alpha G_t \nabla_\theta \log(\pi(A_t | S_t; \theta_t)) \quad (28)$$

El problema de la ecuación (algoritmo REINFORCE) anterior es que la varianza puede tomar valores altos si la recompensa varía mucho. Una solución es restar una referencia en el gradiente del rendimiento:

$$\begin{aligned}\nabla_{\theta} J(\theta) &\propto \sum_s \mu(s) \sum_a (q_{\pi}(s, a) - b(s)) \nabla_{\theta} \pi(a | s; \theta) \\ &= \mathbb{E}_{\pi} \left[\sum_a (q_{\pi}(S_t, a) - b(S_t)) \nabla_{\theta} \pi(a | S_t; \theta) \right]\end{aligned}\tag{29}$$

$$\mathbb{E}_{\pi} \left[\sum_a b(S_t) \nabla_{\theta} \pi(a | S_t; \theta) \right] = \mathbb{E}_{\pi} \left[b(S_t) \nabla_{\theta} \sum_a \pi(a | S_t; \theta) \right] = \mathbb{E}_{\pi} [b(S_t) \nabla_{\theta} 1] = 0\tag{30}$$

$$V(\nabla_{\theta} J(\theta)) = \mathbb{E}_{\pi} \left[((G_t - b(S_t)) \nabla_{\theta} \log \pi(A_t | S_t; \theta))^2 \right] - (\nabla_{\theta} J(\theta))^2\tag{31}$$

El algoritmo anterior se conoce como REINFORCE con línea de base. Cuando $b(S_t) = 0$ se tiene el REINFORCE clásico. Atendiendo a la varianza, solamente el primer término depende de la línea de referencia. Una línea de base conveniente podría ser una aproximación de la función de valor $\hat{v}(S_t, w)$, donde w son los parámetros de la función que la aproxima. El esquema de aprendizaje de este método se podría resumir en:

$$\theta_{t+1} = \theta_t + \alpha (G_t - b(S_t)) \nabla_{\theta} \log \pi(A_t | S_t; \theta_t)\tag{32}$$

2.3.2. Actor-critic

El algoritmo REINFORCE depende del valor de G_t calculado al final del episodio. Por lo tanto, puede pasar mucho tiempo hasta que se produzca una actualización de los parámetros. Siguiendo la filosofía del aprendizaje por diferencias temporales, se podría mirar la aproximación de la función estado-valor antes y después de ejecutar la acción para realizar una actualización a partir de una estimación de la recompensa G_t :

$$\begin{aligned}\theta_{t+1} &= \theta_t + \alpha (R_{t+1} + \gamma \hat{v}(S_{t+1}, w) - \hat{v}(S_t, w)) \nabla_{\theta} \log \pi(A_t | S_t; \theta_t) \\ &= \theta_t + \alpha \delta_t \nabla_{\theta} \log \pi(A_t | S_t; \theta_t)\end{aligned}\tag{33}$$

2.3.3. Soft actor-critic

El algoritmo soft actor-critic es un método off-policy que busca maximizar la recompensa junto con la entropía de la política. De forma genérica:

$$J(\theta) = \mathbb{E}_{S_t, A_t} \left[\sum_{t=0}^{\infty} \gamma^t (R_{t+1} - \alpha \log \pi(A_t | S_t; \theta)) \right]\tag{34}$$

Donde α es un parámetro de temperatura que regula la importancia del término de entropía. Esta formulación presenta varias ventajas:

- La exploración del entorno es más amplia, dejando de lado caminos muy complejos.
- La política captura múltiples maneras de hacer las tareas cercanas a la óptima. Si hubiera varias acciones factibles para resolver una situación, todas tenderían a tener la misma probabilidad.

El problema anterior se puede resolver para problemas tabulares mediante el algoritmo de iteración de política suave, consistente en repetir los siguientes pasos hasta la convergencia a la política óptima[2]:

1. Evaluación suave de la política:

$$Q^{k+1}(s, a) = \mathcal{T}^\pi Q^k(s, a) \quad (35)$$

$$\begin{aligned} \mathcal{T}^\pi Q(s, a) &= \mathbb{E}_\pi [R_{t+1} + \gamma V(S_{t+1}) \mid S_t = s, A_t = a] && \text{(Operador de Bellman)} \\ &= \mathbb{E}_\pi [R_{t+1} \mid S_t = s, A_t = a] + \gamma \mathbb{E}_\pi [V(S_{t+1}) \mid S_t = s, A_t = a] \\ &= r(s, a) + \gamma \mathbb{E}_\pi [V(S_{t+1}) \mid S_t = s, A_t = a] \end{aligned} \quad (36)$$

$$V(s) = \mathbb{E}_{A_t} [Q(S_t, A_t) - \alpha \log \pi(A_t \mid S_t) \mid S_t = s] \quad (37)$$

2. Mejora suave de la política: estima la nueva política minimizando la divergencia de Kullback-Leibler con $\frac{\exp(Q_{\pi_t}(S_t, \cdot))}{Z_{\pi_t}(S_t)}$:

$$\pi_{t+1} = \arg \min_{\pi' \in \Pi} D_{KL} \left(\pi'(\cdot \mid S_t) \left\| \frac{\exp(Q_{\pi_t}(S_t, \cdot))}{Z_{\pi_t}(S_t)} \right\| \right) \quad (38)$$

Esto asegura que $Q_{\pi_t}(s, a) \geq Q_{\pi_t}(s, a) \quad \forall s, a \in \mathcal{S} \times \mathcal{A}$.

Los espacios de acciones y estados continuos y grandes requieren aproximar la iteración de política suave. Es decir, se usan redes neuronales para estimar por descenso del gradiente los parámetros de:

- Función estado-valor: podría obtenerse a partir de la ecuación 37, pero es preferible entrenar una red por motivos de estabilidad. La idea es minimizar la diferencia entre este valor teórico y el aproximado por la red de parámetros ψ :

$$J_V(\psi) = \mathbb{E}_{S_t \sim \mathcal{D}} \left[\frac{1}{2} (V_\psi(S_t) - \mathbb{E}_{A_t \sim \pi_\phi} [Q_\theta(S_t, A_t) - \alpha \log \pi_\phi(A_t \mid S_t)])^2 \right] \quad (39)$$

$$\nabla_\psi J_V(\psi) = \mathbb{E}_{S_t \sim \mathcal{D}} [\nabla_\psi V_\psi(S_t) (V_\psi(S_t) - Q_\theta(S_t, A_t) + \alpha \log \pi_\phi(A_t \mid S_t))] \quad (40)$$

Donde $\mathcal{D}$ es un buffer de repetición característico de los algoritmos off-policy que almacena valores ya observados. En cada iteración, aproxima la esperanza sobre las acciones por el valor de la muestra según la política actual. Además, se puede calcular la esperanza sobre las muestras de políticas pasadas debido a que la política de comportamiento es diferente a la política objetivo.

- Función acción-valor: buscan imitar el operador de Bellman aplicado sobre la función acción valor, minimizando el error a través de la actualización de los parámetros θ de la red:

$$J_Q(\theta) = \mathbb{E}_{(S_t, A_t) \sim \mathcal{D}} \left[\frac{1}{2} (Q_\theta(S_t, A_t) - (R_{t+1} + \gamma \mathbb{E}_{S_{t+1}} [V_{\bar{\psi}}(S_{t+1})]))^2 \right] \quad (41)$$

$$\nabla_\theta J_Q(\theta) = \mathbb{E}_{(S_t, A_t) \sim \mathcal{D}} [\nabla_\theta Q_\theta(S_t, A_t) (Q_\theta(S_t, A_t) - R_{t+1} - \gamma V_{\bar{\psi}}(S_{t+1}))] \quad (42)$$

Donde $\bar{\psi} = \tau\psi + (1 - \tau)\bar{\psi}$ es una media móvil sobre los parámetros de la red de la función acción-valor. Utilizar los pesos $\bar{\psi}$ en este punto ayuda a estabilizar el entrenamiento. Para evitar que la red sea demasiado optimistas, se entrenan dos redes Q de forma independiente y se toma el mínimo entre ambas para actualizar tanto la política objetivo como la función estado-valor.

- Política: miniiza la divergencia de Kullback-Leibler entre la distribución $\frac{\exp(Q_\theta(S_t, \cdot))}{Z_\theta(S_t)}$ deseada de la política y la aproximada por la red mediante los parámetros ϕ :

$$J_\pi(\phi) = \mathbb{E}_{S_t \sim \mathcal{D}, \epsilon_t \sim \mathcal{N}} [\alpha \log \pi_\phi(f_\phi(\epsilon_t; S_t) | S_t) - Q_\theta(S_t, f_\phi(\epsilon_t; S_t))] \quad (43)$$

$$\begin{aligned} \nabla_\phi J_\pi(\phi) = \mathbb{E}_{S_t \sim \mathcal{D}, \epsilon_t \sim \mathcal{N}} & \left[\alpha \nabla_\phi \log \pi_\phi(A_t | S_t) \right. \\ & \left. + (\alpha \nabla_{A_t} \log \pi_\phi(A_t | S_t) - \nabla_{A_t} Q_\theta(S_t, A_t)) \nabla_\phi f_\phi(\epsilon_t; S_t) \right] \end{aligned} \quad (44)$$

Para derivar la política con baja varianza, se emplea el truco de reparametrización: la acción se calcula como una transformación determinista de un ruido externo ϵ_t mediante la red f_ϕ :

$$a_t = f_\phi(\epsilon_t; s_t) \quad (45)$$

2.4. Optimización de cajas negras costosas

Debido al alto costo computacional del entrenamiento en aprendizaje por refuerzo, es fundamental optimizar la búsqueda de hiperparámetros reduciendo las evaluaciones de la función objetivo (en este trabajo, en entrenamientos de 50,000 épocas). En lugar de emplear un barrido por fuerza bruta, se utiliza una estrategia de optimización basada en Estimadores de Parzen en Estructura de Árbol (TPE) [3], la cual permite un muestreo de parámetros más eficiente.

En este artículo se emplea un algoritmo de Optimización Global Secuencial Basada en Modelos (SMBO), detallado en el Algoritmo 1. De manera intuitiva, este procedimiento busca minimizar las evaluaciones de la función de coste $f(x)$ mediante la construcción de modelos bayesianos a partir de un historial de observaciones $\mathcal{H}$, el cual almacena las tuplas de parámetros evaluados y sus respectivos resultados. Para ello, se ajusta un modelo simplificado M_t a la muestra $\mathcal{H}$ utilizando un estimador. En este trabajo se utiliza TPE, aunque el proceso también admite distribuciones normales conjugadas. Dado que optimizar un criterio de selección o función de adquisición $S(x, M_{t-1})$ es computacionalmente mucho más sencillo que evaluar la caja negra original, el algoritmo utiliza este modelo para identificar puntos x^* que ofrezcan una mayor probabilidad de mejorar el rendimiento en la función objetivo reduciendo así el número de llamadas necesarias a la función objetivo.

Algorithm 1 Pseudo-código SMBO.

```

1: SMBO( $f, M_0, T, S$ )
2:  $\mathcal{H} \leftarrow \emptyset$ ,
3: for  $t \leftarrow 1$  to  $T$ , do
4:    $x^* \leftarrow \operatorname{argmax}_x S(x, M_{t-1})$ ,
5:   Evaluate  $f(x^*)$ , ▷ Expensive step
6:    $\mathcal{H} \leftarrow \mathcal{H} \cup (x^*, f(x^*))$ ,
7:   Fit a new model  $M_t$  to  $\mathcal{H}$ .
8: end for
9: return  $\mathcal{H}$ 

```

Para el estimador $S(x, M_{t-1})$ se utiliza el estimador de Mejora Esperada (EI) definido para un problema de maximización como:

$$EI_{y^*}(x) = \int_{-\infty}^{\infty} \max(y - y^*, 0) \cdot p_M(y|x) dy \quad (46)$$

donde y^* representa una cota inferior a partir de la cual aceptar un punto como válido dentro del modelo y $p_M(y|x)$ representa la distribución a posteriori del modelo simplificado de $f(x)$ construida a partir de las distribuciones de verosimilitud de los datos mediante TPE.

La justificación detrás del uso de TPEs y no modelos gaussianos reside en que cuando se ajustan hiperparámetros en modelos por refuerzo o basados en redes el espacio de configuración es jerárquico y hasta cierto punto categórico. En TPE se modelan la probabilidad $p(x|y)$ mediante la partición del espacio muestral $\mathcal{H}$ en dos densidades diferenciadas según una cota de rendimiento y^* :

$$p(x|y) = \begin{cases} \ell(x) & \text{si } y > y^* \\ g(x) & \text{si } y \leq y^* \end{cases} \quad (47)$$

En esta formulación de maximización, $\ell(x)$ representa la densidad de los puntos con mejores resultados (superiores a y^*) y $g(x)$ la del resto de observaciones. El umbral y^* se establece como un cuantil γ del historial, de forma que $p(y > y^*) = \gamma$.

Al aplicar la regla de Bayes, se demuestra que la Mejora Esperada es proporcional a la relación entre estas densidades:

$$EI_{y^*}(x) \propto \left(\gamma + \frac{g(x)}{\ell(x)}(1 - \gamma) \right)^{-1} \quad (48)$$

Esta expresión indica que para maximizar la mejora se deben buscar puntos con una alta probabilidad según $\ell(x)$ y baja probabilidad según $g(x)$. Ambas funciones, se construyen dinámicamente en función de la variable estudiada tal y como se describe a continuación:

- **Variables continuas:** Se utilizan mezclas de Gaussianas equiprobables centradas en cada uno de los valores experimentales obtenidos, donde la desviación típica es la mayor de las distancias a sus vecinos. En este caso, las funciones $\ell(x)$ y $g(x)$ se construyen teniendo en cuenta sólo los puntos que cumplen la inecuación 47. Por tanto, teniendo en cuenta la existencia de una distribución a priori y un parámetro de regularización ω la expresión de estas funciones es:

$$g(x) \text{ o } \ell(x) = w \cdot P_{\text{priori}}(x) + \frac{1 - w}{K} \sum_{i=1}^K \mathcal{N}(x|x^{(i)}, \sigma_i^2) \quad (49)$$

- **Variables discretas:** Suponiendo la distribución a priori como un vector de N probabilidades p_i , la distribución del vector a posteriori es proporcional a $N \cdot p_i + C_i$ con C_i el número de apariciones de la variable i en el espacio muestral.

Así, el algoritmo genera candidatos según $\ell(x)$ y selecciona aquel que maximiza la relación $\ell(x)/g(x)$, optimizando la búsqueda de manera eficiente.

Otro paso adicional que se puede tomar dentro de la optimización de cajas negras costosas como es en el caso del aprendizaje por refuerzo es que, como se obtienen valores intermedios de las evaluaciones, se puede asumir que si un ensayo no es competitivo en sus etapas iniciales, es preferible detener su ejecución para ahorrar recursos (aunque esta suposición es debatible tal y como se verá en los resultados). Para ello, se implementa la Regla de Parada de la Mediana descrita en [4], la cual cancela un ensayo en el paso s si su mejor valor objetivo es estrictamente peor que la mediana de los promedios acumulados de todos los experimentos completados hasta ese mismo punto.

3. Metodología

Para abordar los pasos de entrenamiento, evaluación y análisis del agente de aprendizaje por refuerzo en el entorno del caminante bípedo se ha diseñado una metodología secuencial dividida en cuatro fases.

3.1. Optimización de Hiperparámetros (Finetuning)

Para maximizar el rendimiento del algoritmo Soft Actor-Critic (SAC), se implementó un proceso de búsqueda automatizada de hiperparámetros utilizando la librería *Optuna*.

El primer paso dentro de la optimización consiste en definir el espacio de búsqueda en el cual se definen los siguientes valores a analizar de los hiperparámetros:

- **Tasa de aprendizaje:** Variable continua en escala logarítmica en el intervalo $[10^{-5}, 10^{-2}]$.
- **Tamaño del lote de entrenamiento (*Batch*):** Variable discreta con valores (128, 256, 512).
- **Arquitectura de la red neuronal:** Variable discreta con valores (128, 256, 300, 400) neuronas por capa.
- **Factor de suavizado τ :** Variable continua en escala logarítmica en el intervalo $[0,001, 0,05]$.
- **Factor de descuento γ :** Variable discreta con valores (0,98, 0,99, 0,995, 0,999).

El segundo paso de la optimización consiste en implementar una poda mediante mediana donde evaluando periódicamente cada 10,000 pasos se evalúa el rendimiento de los modelos en la fase de entrenamiento para ver si fuera necesario interrumpir el entrenamiento de manera prematura para así reducir la carga computacional.

Por último, en la fase de ejecución se realizan 100 evaluaciones a la caja negra costosa mediante el optimizador bayesiano de *Optuna* donde cada una de las evaluaciones consistía de un entrenamiento de 50,000 pasos de simulación. Para cada iteración se registraban las métricas de rendimiento y la configuración utilizada en cada caso.

3.2. Entrenamiento del Modelo Final

Tras analizar los resultados de la fase de optimización, se procede a entrenar el agente definitivo utilizando la configuración de hiperparámetros que dan la mejor recompensa tal como se muestra en la tabla 1:

Hiperparámetro	Valor Seleccionado
Algoritmo	Soft Actor-Critic (SAC)
Arquitectura de Red (net_arch)	[256, 256]
Tasa de Aprendizaje (Learning Rate)	$1,965 \times 10^{-4}$
Tamaño de Lote (Batch Size)	512
Factor de Descuento (γ)	0.995
Coefficiente de Suavizado (τ)	0.0388
Coefficiente de Entropía (α)	Automático (<i>auto</i>)
Buffer de Memoria	300,000 pasos

Tabla 1: Configuración de hiperparámetros óptimos seleccionada para el entrenamiento final.

Durante la simulación de 500,000 pasos, se establecieron dos rutinas para el registro de datos. Por un lado, se evalúa el rendimiento cada 1,000 pasos para guardar siempre el mejor modelo

histórico. Por otro, se guardan copias del modelo cada 5,000 pasos con el objetivo de documentar y analizar la evolución cronológica del entrenamiento.

3.3. Simulación y Registro Visual

Para observar cómo aprende a moverse el agente, se creó un script que graba vídeos automáticamente a partir de los modelos guardados durante el entrenamiento.

- **Modificación del entorno:** Se programó un *Wrapper* personalizado que captura cada fotograma del simulador, amplía la imagen y añade una banda de texto en la parte inferior. De este modo, en el vídeo siempre se indica en qué paso del entrenamiento se encuentra el modelo evaluado.
- **Creación del vídeo resumen:** Se ejecutó una simulación de 500 pasos para cada uno de los 60 modelos almacenados. Después, todos estos clips se unieron utilizando FFmpeg sin perder calidad. El resultado es un único vídeo que muestra de forma continua cómo el robot pasa de moverse al azar en los primeros intentos a caminar correctamente.

3.4. Análisis Estadístico y Visualización

La última fase de la metodología consistió en el procesamiento de los registros crudos para evaluar la convergencia y estabilidad del algoritmo matemático tal y como se puede ver en las gráficas de los resultados.

4. Resultados


El primer resultado a mostrar es el del coste computacional del algoritmo que tal y cómo se puede ver en la tabla 2 es elevado pese a que se ha entrenado en una GPU potente como lo es una NVIDIA 4070.

Fase de Trabajo	Tiempo Total
Optimización (Optuna)	8h 22min
Entrenamiento Final (SAC)	2h 26min
Generación de Timelapse	35min
Total Acumulado	11h 23min


Tabla 2: Cronología y Coste Computacional del Proceso de Entrenamiento

La figura 3 se detalla el impacto de los hiperparámetros sobre la recompensa obtenida. Como se observa, en la gran mayoría de los ensayos el agente fue incapaz de avanzar y terminó cayendo rápidamente. Sin embargo, en todas las gráficas destaca un claro outlier positivo, el cual corresponde a la configuración finalmente seleccionada. Este modelo logra mantener al caminante estable durante una mayor cantidad de pasos, convirtiéndose en el mejor candidato al ser el único que mostró signos reales de aprendizaje en 50.000 pasos.


Respecto al resto de combinaciones, resulta complejo extraer conclusiones definitivas. Como se analizará más adelante, el límite de 50.000 pasos fijado para la fase de optimización es un horizonte temporal bastante restrictivo. Los algoritmos de aprendizaje por refuerzo suelen presentar una convergencia no lineal. Pues tal como se verá estos algoritmos atraviesan largas fases iniciales donde la recompensa oscila sin mejoras evidentes, seguidas de un salto abrupto en el rendimiento una vez que el agente asimila aprende a realizar la tarea donde ya se mantendrá estable.




(a) Distribución de Recompensas según Ancho de la Red.



(b) Impacto del Factor de Descuento γ .



(c) Sensibilidad del Parámetro Learning Rate.




(d) Sensibilidad del Parámetro τ .

Figura 3: Análisis de resultados de la optimización de hiperparámetros. Se evalúa el impacto de la arquitectura, el factor de descuento, la tasa de aprendizaje y el suavizado del objetivo en la recompensa máxima.


Como se adelantó previamente, la evaluación temprana de hiperparámetros presenta limitaciones importantes. Las Figuras 4a y 4b muestran que el aprendizaje no es lineal donde la recompensa oscila durante los primeros miles de pasos hasta alcanzar un punto de inflexión donde mejora abruptamente. Por tanto, descartar modelos de forma prematura resulta problemático. De hecho, la Figura 4b ilustra que, incluso entre las mejores configuraciones, el rendimiento inicial es inestable y no garantiza una tendencia.

Por otro lado, la Figura 4a revela un comportamiento interesante ligado a la exploración del algoritmo. Incluso cuando el agente ya domina la tarea, se observan caídas puntuales en la recompensa. Esto ocurre porque el modelo sigue probando variaciones en sus movimientos para descubrir estrategias más óptimas. Asimismo, se detecta una fase intermedia donde la duración de los episodios es muy larga pero la recompensa no es máxima. Haciendo un símil humano, antes de aprender a correr de forma eficiente y directa, el agente primero debe aprender a estabilizarse para no caer y, posteriormente, a caminar con precaución. Esta progresión se corroborará más adelante en el análisis con un vídeo.


Finalmente, la Figura 4c detalla la evolución del coste computacional. Al inicio del entrenamiento, el tiempo invertido por episodio es muy bajo porque el robot pierde el equilibrio casi al instante. Sin embargo, conforme aprende a mantenerse en pie, la duración de cada intento se estabiliza y el tiempo acumulado empieza a crecer de forma lineal. Aunque esta métrica no sirva para predecir el tiempo total de ejecución, proporciona un indicador indirecto para confirmar visualmente el momento exacto en el que el agente aprende a realizar la tarea.



(a) Evolución de la Recompensa a lo largo del Tiempo



(b) Curvas de Convergencia: Top 5 Mejores Modelos




(c) Coste Computacional: Tiempo vs Número de Episodios


Figura 4: Análisis temporal y de convergencia del entrenamiento.

La Figura 5 presenta las métricas fundamentales que validan el éxito del entrenamiento del agente. En la subfigura (a), se aprecia cómo la recompensa de evaluación supera una fase inicial de alta inestabilidad para experimentar un crecimiento abrupto a partir de los 150,000 pasos, convergiendo finalmente hacia la meta de 300 puntos. Este dominio del entorno se corrobora con la subfigura (b), referida a la supervivencia del agente. Durante las primeras fases, el robot agota frecuentemente el límite máximo de la simulación (1600 pasos), lo que indica que sobrevive quedándose genuflectado (como se ve en el vídeo). Sin embargo, una vez que la recompensa se maximiza, la duración de los episodios se reduce y se estabiliza en torno a los 800 pasos. Esto demuestra que el agente no solo ha aprendido a no caerse, sino que ha optimizado su locomoción para cruzar el terreno de la forma más rápida y directa posible.


Por otro lado, las subfiguras (c) y (d) ilustran la convergencia interna y la estabilidad matemática de las redes neuronales del algoritmo *Soft Actor-Critic*. La pérdida del Actor (*Actor Loss*) exhibe un comportamiento característico donde tras una fuerte fluctuación inicial provocada por la alta exploración y el ajuste dinámico de la entropía, la curva desciende de forma suave y monótona hasta alcanzar su estabilización. Simultáneamente, la pérdida del Crítico (*Critic Loss*), representada en escala logarítmica, decrece drásticamente y establece un nivel base bajo. Aunque esta gráfica muestra picos de error constantes a lo largo de todo el entrenamiento, este ruido es normal, pues refleja los instantes en los que el agente experimenta con posturas nuevas o extrae transiciones inusuales de su memoria de repetición, obligando al Crítico a reajustar continuamente sus estimaciones de valor futuro.




(a) Rendimiento del Agente: Evolución de la Recompensa



(b) Supervivencia: Longitud Promedio de los Episodios



(c) Pérdida del Actor (Actor Loss)



(d) Pérdida del Crítico (Critic Loss)

Figura 5: Métricas de progreso durante el entrenamiento del agente final a lo largo de 500,000 pasos. Se observa la convergencia de la recompensa y la supervivencia.

Tras la optimización de hiperparámetros con *optuna* y el entrenamiento final, se comprueba empíricamente que el agente aprende a andar de forma fluida¹.

5. Aspectos éticos en relación al problema

Aunque el entorno abordado en este proyecto se basa en una simulación bidimensional, el desarrollo de agentes autónomos mediante aprendizaje por refuerzo se puede extender al mundo real. La capacidad de enseñar a una máquina a caminar de forma autónoma, adaptándose al entorno sin reglas explícitas programadas a mano obliga a realizar una reflexión sobre su impacto ético y su alineación con los Objetivos de Desarrollo Sostenible (ODS) de la Agenda 2030 de las Naciones Unidas.

5.1. Alineación con los Objetivos de Desarrollo Sostenible (ODS)

El desarrollo de la robótica autónoma y los algoritmos de toma de decisiones impacta positivamente en varios objetivos globales:

- **ODS 3 (Salud y Bienestar):** Una de las transferencias tecnológicas más directas del problema del *Bipedal Walker* es el campo de la biomecánica clínica en el diseño de prótesis robóticas inteligentes. Esto permitiría asistir a personas con discapacidades motoras o en procesos de rehabilitación, adaptando dinámicamente el paso del paciente a diferentes terrenos.

¹Vídeo demostrativo de la evolución del agente: <https://youtu.be/nI3171S9mWE>

- **ODS 9 (Industria, Innovación e Infraestructura):** La optimización de algoritmos como *Soft Actor Critic* impulsa la innovación tecnológica. El uso de robots bípedos permite el acceso en terrenos irregulares donde los vehículos con ruedas no pueden acceder, facilitando la automatización en la inspección de infraestructuras críticas, mantenimiento o logística.
- **ODS 8 (Trabajo Decente y Crecimiento Económico):** Los robots bípedos pueden ser desplegados en entornos de alto riesgo para los humanos, asumiendo las tareas peligrosas y promoviendo un entorno de trabajo más seguro.

5.2. Consideraciones Éticas y Riesgos

A pesar de los beneficios potenciales, la aplicación empírica de este tipo de inteligencia artificial plantea dilemas éticos:

- **Dualidad de Uso:** La robótica con capacidad de desplazamiento todoterreno ha atraído tradicionalmente una gran inversión militar. Existe el riesgo ético de que algoritmos diseñados para la locomoción o el rescate sean adaptados para la creación de sistemas de armas autónomas letales. Como desarrolladores, es crucial abogar por regulaciones que limiten la automatización de la fuerza y prioricen fines civiles y pacíficos.
- **Impacto Medioambiental y ODS 13 (Acción por el Clima):** El entrenamiento de modelos, sumado a la búsqueda exhaustiva de hiperparámetros (*Optuna*) realizada en este estudio, requiere un alto coste computacional. Este uso intensivo de procesamiento conlleva un consumo energético considerable y una huella de carbono asociada.

Referencias

- [1] A. G. Barto, “Reinforcement learning: An introduction. by richard’s sutton,” *SIAM Rev*, vol. 6, no. 2, p. 423, 2021.
- [2] T. Haarnoja, A. Zhou, P. Abbeel, and S. Levine, “Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor,” in *International conference on machine learning*, pp. 1861–1870, Pmlr, 2018.
- [3] J. Bergstra, R. Bardenet, Y. Bengio, and B. Kégl, “Algorithms for hyper-parameter optimization,” in *Advances in Neural Information Processing Systems* (J. Shawe-Taylor, R. Zemel, P. Bartlett, F. Pereira, and K. Weinberger, eds.), vol. 24, Curran Associates, Inc., 2011.
- [4] D. Golovin, B. Solnik, S. Moitra, G. Kochanski, J. E. Karro, and D. Sculley, eds., *Google Vizier: A Service for Black-Box Optimization*, 2017.